

教育经历

• 爱丁堡大学	英国爱丁堡
• 计算机科学博士	2023 年 8 月 - 至今
研究方向: AI 系统、分布式机器学习、面向 ML 的体系结构、无服务器计算	
• 中国科学技术大学	中国合肥
• 计算机科学学士; 少年班学院	2017 年 7 月 - 2021 年 6 月
核心课程: 操作系统、人工智能、编译原理、计算机体系结构、高性能体系结构	

学术论文

1 **Yeqi Huang**, Congjie He, Haocheng Xiao 等. “Wavel: A Fast and Efficient Compilation System for Wafer-Scale Accelerators.” 已被 ACM 操作系统原理研讨会 (SOSP) 录用, 2026.

2 Congjie He, Le Xu, Zhan Lu, **Yeqi Huang** 等. “MeshRT: Compile-Time Governed Wafer-Scale Runtime for Low-Latency High-Throughput Inference.” 已被 ACM 操作系统原理研讨会 (SOSP) 录用, 2026.

3 **Yeqi Huang**, Yanwei Ye, Guomin Chen 等. “SwarmPilot: A Scheduler Agent Framework for Large Agentic Workflow Clusters.” 已被欧洲计算机系统会议 (EuroSys) 录用, 2026.

4 **Yeqi Huang**, Yue Chen, Yanwei Ye 等. “Ryze: Evidence-Enriched Data Synthesis from Biomedical Papers.” 发表于第 64 届计算语言学协会年会 (ACL 2026) 系统演示论文集, 2026.

5 Chuanming Zha, Jiamin Zheng, **Yeqi Huang** 等. “LLM-Monitor: Efficient Privacy Violation Monitoring for LLMs.”

6 Yinsicheng Jiang*, **Yeqi Huang***, Liang Cheng 等. “ContextPilot: Fast Long-Context Inference via Context Reuse.” 发表于 机器学习与系统会议 (MLSys) 论文集, 2026. (* 共同一作)

7 Congjie He, **Yeqi Huang**, Pei Mu 等. “WaferLLM: Large Language Model Inference at Wafer Scale.” 发表于第 19 届 USENIX 操作系统设计与实现研讨会 (OSDI 25), 2025.

8 Yinsicheng Jiang*, Yao Fu*, **Yeqi Huang*** 等. “MoE-CAP: Benchmarking Cost, Accuracy and Performance of Sparse Mixture-of-Experts Systems.” 发表于 神经信息处理系统大会 (NeurIPS) 论文集, 2025. (* 共同一作)

9 Yao Fu, Leyang Xue, **Yeqi Huang** 等. “ServerlessLLM: Low-Latency Serverless Inference for Large Language Models.” 发表于第 18 届 USENIX 操作系统设计与实现研讨会 (OSDI 24), 2024.

10 Xiao-Long Chen, Lin-Feng Wang, **Yeqi Huang** 等. “Symplectic Structure-Preserving Particle-in-Cell Whole-Volume Simulation of Tokamak Plasmas.” 发表于 SC21: 国际高性能计算、网络、存储与分析会议, 2021.

项目经历

- **Wavel (SOSP 2026)**: 设计 MeshIR 与局部性保持的晶圆级调度搜索, 实现最高 3.6 倍加速, 并将搜索时间从数周缩短至数秒。
- **MeshRT (SOSP 2026)**: 将动态 LLM 推理事件编译为去中心化的逐核调度, 在保持超低延迟的同时将吞吐量提升 30–68 倍。
- **SwarmPilot (EuroSys 2026)**: 开发结合神经预测器、记忆、工具与协作机制的调度智能体; 生产部署使 P99 延迟最高降低 50%, 吞吐量翻倍。
- **Ryze (ACL 2026 Demo)**: 构建证据增强的生物学 VLM 数据流水线, 并对 Qwen3-VL-8B 进行 SFT 与 RL 后训练, 以低于 200 美元成本在 LAB-Bench 上超过 GPT-5.2。
- **LLM-Monitor**: 将隐私策略编译为高效的本地模型监控器; 基于 Qwen3-8B 的专用模型以 15 倍速度达到 GPT-5.2 监控质量。
- **AutoReader**: 构建科学文献的图与向量检索系统, 索引速度比 NVIDIA cuVS 快 60 倍, 检索速度比 Milvus 快 13 倍。
- **AI4Math - Sketchpad**: 构建获 AI for Math 基金资助的系统, 将数学证明转化为结构化图并分解, 以支持更精确的自动形式化。
- **GPU 上的 QED 模拟**: 实现 CUDA 蒙特卡罗模拟, 获得 1500–5000 倍加速, 并在 APS 会议上获得诺贝尔奖得主 Frank Wilczek 认可。

学术报告

- 1 **Yeqi Huang**. “InfiniTensor: A Tensor-Friendly, Efficient Parallel Programming Library for Accelerator-Centric Clusters.” *UKSys*, 2024.
- 2 **Yeqi Huang**. “Why we need a new clustering benchmark in AI retrieval?” *Int’l Workshop on Efficient Generative AI*, 2024.

教学经历

- **机器学习系统助教 (2025):**
 - 担任 CUDA 编程课程助教，涵盖 GPU 架构、CUDA、CuPy 和 Triton。
 - 设计动手实验和项目，帮助学生掌握并行编程概念。
- **机器学习系统助教 (2026):**
 - 担任助教，新增 CuTile 编程模块，教授基于 Tile 的 GPU 编程。

获奖经历

- 国际奖项:**
- 国际超级计算大会学生集群竞赛冠军 - 2021
 - 亚洲超算大会学生集群竞赛一等奖 - 2021
- 国内奖项:**
- 年度最佳中国超算应用 - 2022
 - 华为先锋开发者（全国仅 4 人）- 2021
 - 全国编译系统设计赛二等奖 - 2021

专业技能

- **LLM 系统与推理:** 高性能服务、分布式与晶圆级推理、批处理与 MoE 动态运行时、模型加载与迁移、KV/上下文复用，以及 GPU、Apple Silicon 和 Cerebras 上的跨硬件优化。
- **LLM 训练与评测:** 证据增强数据合成、SFT 与 RL 后训练、推理时扩展，以及面向 LLM/VLM 的质量、延迟、吞吐量、能效和成本评测。
- **RAG 与智能体:** 向量与图检索、上下文索引与去重、多智能体 workflow、神经预测、记忆与工具抽象，以及 Ray 和 ComfyUI 生产集成。
- **系统与编程:** C++、Python、Rust; CUDA、CuPy、Triton、CuTile、MLIR/LLVM、OpenMP、Linux/eBPF、分布式系统、编译工具与性能工程。
- **物理与数学:** 数值方法、线性代数、计算流体力学、分子动力学、量子力学与量子电动力学。

特殊经历

- **开源爱好者:** 参与贡献 GNOME、LAMMPS 和 LLVM 等知名项目，自 2019 年起使用 GitHub 展示开发历程和创意。
- **经营科学主题咖啡馆:** 利用软件开发收入，在学校附近创办了 Quantum Coffee——一个鼓励学生跨学科探索和讨论科学话题的协作空间。
- **UNICEF 慈善项目:** 自 2019 年起，将个人全部收入的 10% 捐赠给儿童慈善机构。