

教育经历

• 爱丁堡大学	英国爱丁堡
• 计算机科学博士	2023 年 8 月 - 至今
研究方向: AI 系统、分布式机器学习、面向 ML 的体系结构、无服务器计算	
• 中国科学技术大学	中国合肥
• 计算机科学学士; 少年班学院	2017 年 7 月 - 2021 年 6 月
核心课程: 操作系统、人工智能、编译原理、计算机体系结构、高性能体系结构	

学术论文

1 **Yeqi Huang**, Congjie He, Haocheng Xiao 等. “Wavel: A Fast and Efficient Compilation System for Wafer-Scale Accelerators.” 已被 ACM 操作系统原理研讨会 (SOSP) 录用, 2026.

2 Congjie He, Le Xu, Zhan Lu, **Yeqi Huang** 等. “MeshRT: Compile-Time Governed Wafer-Scale Runtime for Low-Latency High-Throughput Inference.” 已被 ACM 操作系统原理研讨会 (SOSP) 录用, 2026.

3 **Yeqi Huang**, Yanwei Ye, Guomin Chen 等. “SwarmX: Agentic Cluster Scheduling Framework.” 审稿中, OSDI 2026.

4 **Yeqi Huang**, Yue Chen, Yanwei Ye 等. “BioVLM: Evidence-Enriched Data Synthesis from Biomedical Papers.” 审稿中, ACL 2025 系统演示.

5 Chuanming Zha, Jiamin Zheng, **Yeqi Huang** 等. “LLM-Monitor: Efficient Privacy Violation Monitoring for LLMs.”

6 Yinsicheng Jiang*, **Yeqi Huang***, Liang Cheng 等. “ContextPilot: Efficient Retrieval-Augmented Generation with Accuracy-Preserving Context Reuse.” *MLSys*, 2026. (* 共同一作)

7 Congjie He, **Yeqi Huang**, Pei Mu 等. “WaferLLM: Large Language Model Inference at Wafer Scale.” 审稿中, OSDI 2025.

8 Yao Fu*, Yinsicheng Jiang*, **Yeqi Huang*** 等. “MoE-CAP: Cost-Accuracy-Performance Benchmarking for Mixture-of-Experts Systems.” *NeurIPS*, 2025. (* 共同一作)

9 Yao Fu, Leyang Xue, **Yeqi Huang** 等. “ServerlessLLM: Locality-Enhanced Serverless Inference for Large Language Models.” 发表于 第 18 届 USENIX 操作系统设计与实现研讨会 (OSDI 24), 2024.

10 Xiao-Long Chen, Lin-Feng Wang, **Yeqi Huang** 等. “Symplectic structure-preserving particle-in-cell whole-volume simulation of tokamak plasmas.” 发表于 SC21: 国际高性能计算、网络、存储与分析会议, 2021.

项目经历

- GPU 上的 QED 模拟:
 - 实现了高性能蒙特卡罗模拟, 实现 1500 至 5000 倍加速。
 - 在 APS 会议上获得诺贝尔奖得主 Frank Wilczek 的认可。
 - 展示了 CUDA 编程和 GPU 微架构优化方面的专业技能。
- AutoReader 项目:
 - 构建了面向最新 ArXiv 论文的向量数据库, 支持每日语义搜索和订阅。(全栈 AI 应用)
 - 实现了比 NVIDIA cuVS 快 60 倍的索引速度和比 Milvus 快 13 倍的检索速度。
 - 扩展系统支持 bioRxiv 和 PubMed 论文, 具备专业的生物学功能。
 - 生物学版本正在达特茅斯大学进行演示, 计划今年向 Nature 投稿。

- **Wavel (SOSP 2026)** :
 - 设计了使用 MeshIR 及局部性保持原语 CUT 和 TUNE 的晶圆级编译系统。
 - 相比最先进编译器实现最高 3.6 倍加速, 相比 WaferLLM 吞吐量提升 1.3–1.4 倍, 相比自动基线最高提升 2.97 倍。
 - 在 Cerebras WSE-3 和 Tenstorrent Blackhole 上达到或超过专家调度, 并将搜索时间从数小时或数周缩短至数分钟或数秒。
- **MeshRT (SOSP 2026)** :
 - 开发了首个同时实现超低延迟和高吞吐量的晶圆级 LLM 推理运行时。
 - 将动态推理事件编译为逐核调度, 实现低运行时开销的去中心化执行。
 - 吞吐量提升最高 30–68 倍; 在低延迟场景下, 相比 H200 GPU 推理引擎实现 6–8 倍更低延迟和 10–36 倍更高解码能效。
- **SwarmX (已投稿 OSDI 2026)** :
 - 提出首个将集群调度建模为智能体问题的调度器代理框架。
 - 在数万台服务器上进行生产部署, P99 延迟降低最高 50%, 吞吐量翻倍。
 - 设计了带有神经预测器和记忆模块的模块化代理, 优化复杂工作流性能。
 - 保持与 Ray 和 ComfyUI 的兼容性, 现有工作流无需修改即可运行。
- **BioVLM (已投稿 ACL 2025 系统演示)** :
 - 自动化流水线将生物医学论文转化为证据增强的 VLM 训练数据。
 - 在 Qwen3-VL-8B 上进行渐进式后训练 (SFT + RL), 以低于 200 美元成本训练 BioVLM-8B。
 - 在 LAB-Bench 上达到 48.0% 加权准确率, 比基础模型高 12.6%, 比 GPT-5.2 高 3.8%。
- **LLM-Monitor**:
 - 设计了面向 LLM 的低成本、高质量、可进化的隐私违规监控系统。
 - 将监控需求组织编译为本地中等规模模型可执行的优化表示。
 - 使用基于 Qwen3-8B 的专用模型, 实现比 GPT-5.2 高 15 倍的监控加速。
 - 匹配大型公共模型 (GPT-5.2) 的监控质量, 同时显著更快更便宜。
- **AI4Math - Sketchpad 项目**:
 - 获得 AI for Math 基金资助, 开发面向形式数学的 Sketchpad 系统 (公告链接)
 - 构建自动将数学证明转化为结构化数据的系统, 采用基于图的表示。
 - 实现将证明分解为单独命题, 以实现更精确的自动形式化。
- **更多项目 (<https://yeqi-huang.com/>):**
 - 更多 AI 相关项目请访问我的个人主页。

学术报告

- 1 **Yeqi Huang**. “InfiniTensor: A Tensor-Friendly, Efficient Parallel Programming Library for Accelerator-Centric Clusters.” *UKSys*, 2024.
- 2 **Yeqi Huang**. “Why we need a new clustering benchmark in AI retrieval?” *Int’l Workshop on Efficient Generative AI*, 2024.

教学经历

- **机器学习系统助教 (2025)**:
 - 担任 CUDA 编程课程助教, 涵盖 GPU 架构、CUDA、CuPy 和 Triton。
 - 设计动手实验和项目, 帮助学生掌握并行编程概念。
- **机器学习系统助教 (2026)**:
 - 担任助教, 新增 CuTile 编程模块, 教授基于 Tile 的 GPU 编程。

获奖经历

国际奖项:

- 国际超级计算大会学生集群竞赛冠军 - 2021
- 亚洲超算大会学生集群竞赛一等奖 - 2021

国内奖项:

- 年度最佳中国超算应用 - 2022
- 华为先锋开发者 (全国仅 4 人) - 2021
- 全国编译系统设计赛二等奖 - 2021

专业技能

- **AI 相关:**
 - 深入理解大语言模型，具有将高性能推理和训练框架移植到 Apple Silicon、GPU 和 Cerebras 等多种硬件平台的经验。
 - 深入理解向量检索，在多个平台上开发和测试过图数据库和向量数据库。
 - 深入了解多智能体应用，开发了面向此类应用的高效开发组件。
- **计算机科学相关:**
 - 精通 **C++**、**Python**、**Rust**；熟悉 Go、JavaScript 和 LaTeX
 - 精通 **CUDA**、**Intel ONEAPI**、**OpenMP** 及相关并行与分布式编程
 - 精通 **LLVM**，经常参与 LLVM 论坛在线讨论
 - 丰富的 Linux 使用经验，包括 eBPF 的使用
 - 丰富的分布式系统和分布式机器学习框架经验
 - 扎实的工程开发经验，掌握各类编译器相关工具和静态分析工具
- **物理与数学:**
 - 精通计算流体力学和分子动力学
 - 扎实的数值方法和线性代数知识
 - 精通量子力学和量子电动力学，了解量子计算

特殊经历

- **开源爱好者:** 参与贡献 GNOME、LAMMPS 和 LLVM 等知名项目，自 2019 年起使用 GitHub 展示开发历程和创意。
- **经营科学主题咖啡馆:** 利用软件开发收入，在学校附近创办了 Quantum Coffee——一个鼓励学生跨学科探索和讨论科学话题的协作空间。
- **UNICEF 慈善项目:** 自 2019 年起，将个人全部收入的 10% 捐赠给儿童慈善机构。